Trabajo Aprendizaje Automático II



Marcos Jiménez González

Aprendizaje Automático II

Índice

Resumen del trabajo previo 2
Modelos de Aprendizaje Automático (Ampliación) 3
Selección de características (Ampliación con PCA) 4
Resultados 4
Discusión 5
Conclusiones 6

Resumen del trabajo previo

El proyecto se basa en un trabajo que hice anteriormente en Aprendizaje Automatico I en el que desarrollé un sistema de clasificación para la predicción de enfermedad cardíaca utilizando el conjunto de datos *Heart Disease* del repositorio UCI.

En el trabajo anterior hice un análisis de datos, comenzando por el preprocesamiento, que incluyó la revisión de valores nulos, el análisis de valores atípicos mediante diagramas de caja, la normalización de variables numéricas y la preparación del conjunto de datos para su posterior modelado. También hice una exploración estadística mediante histogramas y matrices de correlación para comprender la distribución y relación entre variables.

Después, entrené y evalué los siguiente modelos de aprendizaje automático supervisado: Regresión Logística, Árbol de Decisión, Random Forest y Support Vector Machine (SVM). Todos los modelos fueron implementados con pipelines y evaluados utilizando métricas estándar como accuracy, precision, recall y F1-score.

Los resultados que obtení mostraron que la Regresión Logística fue el modelo con mejor rendimiento global. Además, al usar Random Forest, pude identificar los atributos más relevantes desde el punto de vista predictivo.

Ese trabajo sienta las bases del actual, sobre el cual se incorporan nuevas técnicas y algoritmos con el objetivo de mejorar el rendimiento y ampliar el análisis del problema.

Modelos de Aprendizaje Automático (Ampliación)

Además de los modelos previamente analizados, he incorporado dos nuevas técnicas con el objetivo de evaluar posibles mejoras en el rendimiento del sistema:

K-Nearest Neighbors (KNN)
El algoritmo KNN es un método basado en instancias que clasifica una muestra en función de la clase mayoritaria de sus vecinos más cercanos en el espacio de características.

Lo he implementado mediante un pipeline con preprocesamiento y he realizado una optimización de hiperparámetros utilizando GridSearchCV, considerando:

- Número de vecinos (k): 3, 5, 7, 9

- Tipo de ponderación: uniforme y por distancia
- Métrica de distancia: euclidiana y Manhattan

Esto me permite identificar la mejor configuración del modelo en función de la métrica de accuracy.

Selección de características (Ampliación con PCA)

He incorporado la técnica Principal Component Analysis (PCA) como método de reducción de dimensionalidad.

En lugar de priorizar la interpretabilidad clínica en el modelo anterior, al usar PCA me permite transformar las variables originales en un conjunto reducido de componentes principales que capturan la mayor parte de la varianza del dataset.

En este caso:

- He podido conservar el 95% de la varianza
- Se ha integrado dentro de un pipeline junto con Regresión Logística
- También he añadido una proyección a 2 componentes para visualización

La visualización de las dos primeras componentes me permite observar la distribución de las clases en un espacio reducido, facilitando la interpretación de la separabilidad de los datos.

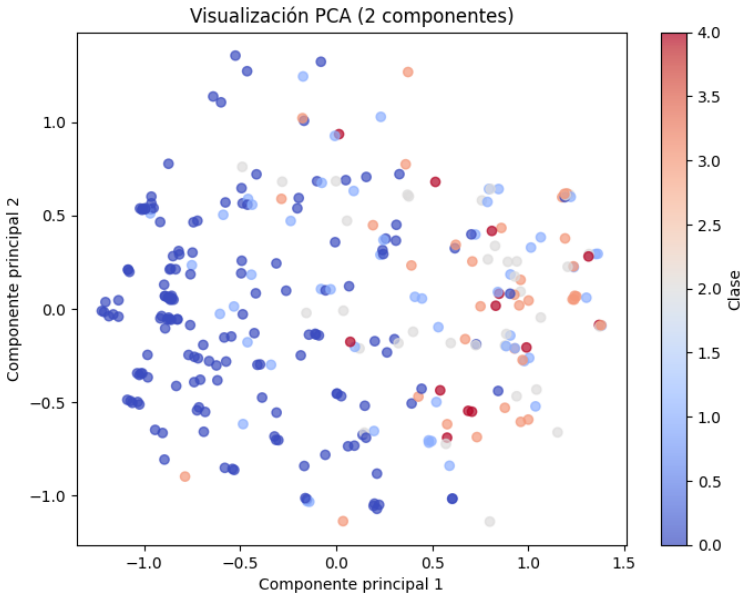
Resultados

Modelo	Precision	Recall	F1-score
KNN	0.466601	0.566667	0.506583
KNN OPT	0.460240	0.566667	0.493695

Descripción:

El modelo KNN me ha dado un rendimiento moderado, con valores cercanos a otros modelos como SVM, aunque por debajo de la Regresión Logística (0.52915; 0.600000;0.557265). Al optimizar los hiperparámetros no produjo una mejora significativa, lo que sugiere limitaciones inherentes del algoritmo en este problema.

Por otro lado, la aplicación de PCA junto con Regresión Logística me ha permitido reducir la dimensionalidad del dataset manteniendo la mayor parte de la información relevante, sin una pérdida significativa de rendimiento en comparación con el modelo original.



Discusión

- Al incorporar KNN y PCA, he podido obtener una perspectiva más completa sobre el comportamiento del dataset y de los modelos:
- El modelo KNN me ha dejado ver que es muy sensible a la escala de los datos, lo que justifica la necesidad de aplicar normalización previa. Aunque su rendimiento es aceptable, se ve limitado por la dimensionalidad del problema y el tamaño reducido del dataset, lo que dificulta la correcta identificación de vecinos representativos. Además, la optimización de hiperparámetros no ha supuesto una mejora clara, indicando que el modelo tiene ciertas limitaciones estructurales en este contexto.
- Por otro lado, el uso de PCA me permitió simplificar el espacio de características, reduciendo la dimensionalidad y eliminando parte del ruido presente en los datos. Sin embargo, esta reducción implica una pérdida de interpretabilidad.

Conclusiones

- Incluir nuevos algoritmos me ha permitido reforzar y ampliar las conclusiones del estudio:
- KNN es una alternativa válida, aunque su rendimiento es inferior al de modelos como la Regresión Logística, especialmente en datasets pequeños y con alta dimensionalidad.
- La optimización de KNN no ah dado mejoras significativas, por lo que saco de conclusión después de realizar este trabajo que no todos los algoritmos sirven para todos los datasets.
- PCA permite reducir la dimensionalidad del dataset sin degradar notablemente el rendimiento del modelo. Muy util.
- Sin embargo, esta reducción conlleva una pérdida de interpretabilidad, lo cual es un factor importante en el contexto clínico.
- En general, concluyo que los modelos más simples y bien ajustados siguen siendo los más adecuados para este tipo de problema, incluso frente a técnicas más complejas o transformaciones adicionales de los datos. Por lo que me queda claro que lo simple a veces es la mejor opción.